

Automatyzacja wykrywania słów z nagrania rozmowy oraz analiza wpływu zmęczenia

Edyta Skwarczek

Warunki przeprowadzenia akwizycji

Nagranie „wieczor” zarejestrowano 10 kwietnia po godzinie 21:00 w formacie M4A, przy użyciu zewnętrznego mikrofonu krawatowego marki BOYA (1 kanał – mono), z częstotliwością próbkowania 48 kHz oraz przepływnością 128 kb/s. W nagraniu brały udział dwie osoby – Edyta Skwarczek oraz Jakub (osoba spoza uczelni). Nagranie trwa 3 minuty i 22 sekundy i zostało wykorzystane w analizie liczenia słów. Jego fragment (fragment 4 Edyty, a całościowo fragment 8) posłużył również do analizy wpływu zmęczenia.

Nagranie „rano” zarejestrowano 11 kwietnia po godzinie 11:00, również w formacie M4A, przy użyciu zewnętrznego mikrofonu krawatowego marki BOYA (1 kanał – mono), z częstotliwością próbkowania 48 kHz oraz przepływnością 128 kb/s. W nagraniu brała udział jedna osoba – Edyta Skwarczek. Fragment tego nagrania został wykorzystany do analizy wpływu zmęczenia.

Oba nagrania przekonwertowano na format mp3.

Opis schematu przetwarzania


1. Wyodrębnienie fragmentów

Na początek zastosowano ekstrakcję cech przy użyciu `audioFeatureExtractor()`. Kluczowym parametrem decyzyjnym był pitch, który posłużył do rozróżnienia mówców.

W celu redukcji szumu i stabilizacji estymacji pitch zastosowano dwuetapowe wygładzanie: najpierw uśrednianie w oknach o długości 95 próbek (z pominięciem wartości zerowych i NaN), a następnie filtrację medianową o rzędzie 3. Taki dobór parametrów pozwolił ograniczyć wpływ błędnych detekcji wysokości tonu oraz krótkotrwałych zakłóceń.

Segmentacja została przeprowadzona pośrednio poprzez detekcję fragmentów należących do drugiego mówcy (Jakuba), przyjmując próg decyzyjny $\text{pitch} < 190 \text{ Hz}$. Dodatkowo zastosowano filtr długości segmentów (minimum 10 s), co eliminowało krótkie, niestabilne fragmenty.

Docelowe fragmenty wyznaczono jako dopełnienie czasowe segmentów Jakuba, z uwzględnieniem minimalnej przerwy 0.5 s jako warunku rozdzielającego wypowiedzi. Przyjęto więc, że moje fragmenty charakteryzują się wyższym zakresem pitch ($\geq 190 \text{ Hz}$) oraz występują w przerwach między dłuższymi segmentami drugiego mówcy.



1. Sygnał audio nagrania, podzielony kolorystycznie na osoby mówiące

2. Liczenie słów


Detekcja słów została oparta na analizie obwiedni energii (RMS, okno 30 ms) oraz współczynnika przejść przez zero (ZCR, krok 10 ms). Utworzono cechę złożoną jako sumę energii i ważonego ZCR (waga 0.1), a następnie wygładzono ją filtrem Gaussa (okno ~60 ms), co odpowiada filtracji dolnoprzepustowej w dziedzinie czasu.

Liczbę słów wyznaczano poprzez detekcję maksimów lokalnych tej cechy. Progi detekcji ustalano indywidualnie dla każdego fragmentu jako: średnia + (współczynnik progowy $\times$ odchylenie standardowe), gdzie współczynniki progowe wynosiły odpowiednio: 0.06, 0.05, 0.20, 0.35. Minimalne odległości między pikami (determinujące rozdzielczość słów) przyjęto jako: 0.19 s, 0.25 s, 0.15 s oraz 0.19 s.

Tak dobrane parametry pozwalają na adaptacyjne dopasowanie do zmienności tempa mowy i dynamiki sygnału w poszczególnych fragmentach, przy jednoczesnym ograniczeniu fałszywych detekcji.

1. Opis danych wejściowych dla każdego fragmentu osobno z wartościami wyznaczonymi ręcznie i przy użyciu algorytmu

Numer fragmentu	Początek [s]	Koniec [s]	Czas trwania	Ilość słów wypowiedzianych	Ilość słów obliczonych	Błąd [%]	
1	26,35	46,61	20,27	45	44	2,22	
2	68,91	98,29	29,39	56	61	8,93	
3	115,52	133,76	18,24	47	48	2,13	
4	158,08	177,33	19,25	42	42	0,00	
Suma	-	-	-	190	195	Średni błąd:	3,68



2. Wykresy z zaznaczonymi zakresami słów dla każdego z fragmentów czytanych przez autorkę sprawozdania (Edyta)

Analiza wpływu zmęczenia

Do analizy wykorzystano dwa fragmenty nagrań opisanych wcześniej w sprawozdaniu. Pierwszy z nich pochodzi z nagrania „wieczór” i obejmuje zakres od 158,08 do 177,33 sekundy oryginalnego nagrania. Został on wybrany ze względu na najniższy poziom błędów w automatycznym rozpoznawaniu słów w pierwszym zadaniu. Drugi fragment pochodzi z nagrania „rano” i zawiera czytanie tego samego tekstu przez tę samą osobę (autorkę sprawozdania), co zapewnia porównywalność materiału.

Dla obu analizowanych fragmentów uzyskano pełną skuteczność detekcji – poprawnie rozpoznano wszystkie słowa (42/42).

2. Statystyki tempa mowy fragmentu "wieczór"

Parametr	Wartość
Minimalny czas	0.035 s
Maksymalny czas	0.356 s
Średni czas	0.130 s
Liczba słów szybszych	28
Liczba słów wolniejszych	14
Różnica (max - min)	0.321 s

3. Statystyki tempa mowy fragmentu "rano"

Parametr	Wartość
Minimalny czas	0.018 s
Maksymalny czas	0.395 s
Średni czas	0.126 s
Liczba słów szybszych	25
Liczba słów wolniejszych	17
Różnica (max - min)	0.377 s

Tempo mowy w obu nagraniach jest bardzo zbliżone. Wieczorem wynosi ono 0,130 s, natomiast rano 0,126 s, co oznacza minimalną różnicę. Można więc stwierdzić, że zmęczenie nie wpływa istotnie na ogólne tempo mówienia.

Widoczne różnice dotyczą natomiast zmienności tempa. Rano zakres czasów jest większy niż wieczorem, co wynika zarówno z niższego minimum, jak i wyższego maksimum. Rano wypowiedź jest mniej równomierna – pojawiają się zarówno bardzo szybkie, jak i wyraźnie wolniejsze słowa.

Rozkład liczby słów szybszych i wolniejszych również wskazuje na większą stabilność wieczorem (28 szybszych, 14 wolniejszych) w porównaniu do bardziej wyrównanego rozkładu rano (25 szybszych, 17 wolniejszych).

Wyniki sugerują, że zmęczenie nie zmienia znacząco średniego tempa mowy, ale wpływa na jego regularność. Wieczorem mowa jest bardziej wyrównana, natomiast rano charakteryzuje się większą zmiennością.

4. Statystyki przerw między słowami we fragmencie "wieczor"

Parametr	Wartość
Minimalna przerwa	0.058 s
Maksymalna przerwa	1.206 s
Średnia przerwa	0.337 s
Różnica (max - min)	1.148 s
Trend	Przerwy maleją

5. Statystyki przerw między słowami we fragmencie "rano"

Parametr	Wartość
Minimalna przerwa	0.034 s
Maksymalna przerwa	1.031 s
Średnia przerwa	0.308 s
Różnica (max - min)	0.997 s
Trend	Przerwy rosną

Występują niewielkie różnice między nagraniami. Wieczorem średnia przerwa wynosi 0,337 s, natomiast rano 0,308 s. Rano przerwy są przeciętnie krótsze, co może sugerować nieco bardziej płynną wypowiedź.

Wyraźniejsze różnice widoczne są w zmienności przerw. Wieczorem zakres przerw jest większy (1,148 s) niż rano (0,997 s), co oznacza większe wahania długości pauz w stanie zmęczenia. Dłuższe maksymalne przerwy wieczorem (1,206 s) mogą wskazywać na chwilowe zawahania lub potrzebę regeneracji podczas mówienia.

Istotna jest również zmiana trendu. Wieczorem przerwy stopniowo się skracają, co oznacza, że mówca z czasem przyspiesza tempo wypowiedzi. Rano obserwuje się odwrotną tendencję – przerwy wydłużają się.

Wyniki sugerują, że zmęczenie wpływa bardziej na dynamikę wypowiedzi niż na jej średnie parametry. Wieczorem mowa zaczyna się wolniej, ale staje się coraz bardziej płynna. Rano natomiast początkowo jest bardziej dynamiczna, jednak z czasem tempo ulega spowolnieniu poprzez wydłużanie przerw.

6. Zmiany tonu podstawowego dla poszczególnych fonemów dla pierwszych 10 słów fragmentu nagrania "wieczor"

Słowo	Min (Hz)	Max (Hz)	Średni (Hz)	Zmienność (Hz)	Wniosek
1	262.3	400.0	290.7	137.7	Bardzo duża zmienność
2	240.0	268.2	250.1	28.2	Stabilny ton
3	224.3	252.6	241.9	28.3	Stabilny ton
4	225.4	256.7	234.0	31.3	Umiarkowana zmienność
5	207.8	235.3	219.5	27.5	Stabilny ton
6	233.0	242.4	239.6	9.4	Bardzo stabilny ton
7	240.0	279.1	262.5	39.1	Wyraźniejsza modulacja
8	217.2	235.3	220.5	18.1	Niewielka zmienność
9	218.2	251.3	232.7	33.1	Umiarkowana zmienność
10	79.3	358.2	207.5	278.9	Ekstremalna zmienność (możliwy błąd pomiaru lub silna intonacja)

7. Zmiany tonu podstawowego dla poszczególnych fonemów dla pierwszych 10 słów fragmentu nagrania "rano"

Słowo	Min (Hz)	Max (Hz)	Średni (Hz)	Zmienność (Hz)	Wniosek
-------	----------	----------	-------------	----------------	---------

1	241.2	252.6	247.7	11.4	Bardzo stabilny ton
2	240.0	400.0	274.1	160.0	Bardzo duża zmienność
3	260.9	335.7	293.6	74.8	Wyraźna modulacja
4	233.0	240.0	237.0	7.0	Bardzo stabilny ton
5	277.5	309.7	298.9	32.2	Umiarkowana zmienność
6	205.1	211.5	209.1	6.3	Bardzo stabilny ton
7	214.3	215.2	214.6	1.0	Ekstremalnie stabilny (niemal monotonia)
8	195.1	227.5	206.0	32.4	Umiarkowana zmienność
9	166.7	219.2	203.9	52.5	Dość duża zmienność
10	262.3	287.4	278.3	25.1	Niewielka–umiarkowana zmienność

Analiza dla pierwszych 10 słów wskazuje na różnice w sposobie modulacji głosu między nagraniem wieczornym a porannym.

W nagraniu wieczornym dominuje umiarkowana lub niewielka zmienność tonu – większość słów charakteryzuje się stabilnym przebiegiem tonu podstawowego (np. słowa 2, 3, 5, 6). Pojawiają się jednak pojedyncze przypadki wyraźnej modulacji (słowo 1 i 7), a także jedna wartość skrajna (słowo 10), która może wynikać z silnej intonacji lub błędu pomiarowego. Ogólnie wypowiedź ma charakter dość wyrównany, z ograniczoną liczbą wyraźnych akcentów.

W nagraniu porannym obserwuje się większe zróżnicowanie. Obok bardzo stabilnych fragmentów (np. słowa 4, 6, 7), pojawiają się wyraźne skoki tonu (słowa 2 i 3), wskazujące na silniejszą modulację i większą ekspresję. Zakres zmienności jest częściej wyższy niż w nagraniu wieczornym, choć nie występują tak skrajne wartości jak w słowie 10 w nagraniu wieczornym.

Porównując oba nagrania, można zauważyć, że:

- wieczorem ton jest bardziej wyrównany i stabilny, z rzadszymi zmianami,
- rano występuje większa dynamika – częstsze przejścia między tonem stabilnym a wyraźnie modulowanym.

Wyniki tej analizy sugerują, że zmęczenie prowadzi do bardziej monotonnego i mniej zróżnicowanego przebiegu tonu podstawowego, natomiast stan wypoczęcia sprzyja większej ekspresji i zmienności intonacyjnej wypowiedzi.

Listing wypowiedzi z podziałem na fragmenty

8. Wykryte przedziały słów z fragmentu "wieczor"

Nr słowa	Start (s)	Koniec (s)
1	0.00	0.28
2	0.49	0.64
3	0.93	1.01
4	1.40	1.63
5	1.85	2.12
6	2.76	2.91
7	3.01	3.20
8	3.69	3.88
9	4.34	4.48
10	4.69	4.76
11	5.41	5.66
12	5.90	6.03
13	6.31	6.39
14	6.61	6.66
15	6.78	6.98
16	7.55	7.64
17	7.89	7.94
18	8.08	8.29
19	8.36	8.44
20	8.68	8.78

21	8.96	9.05
22	9.51	9.62
23	10.43	10.51
24	11.28	11.53
25	11.62	11.67
26	12.02	12.13
27	13.33	13.40
28	13.66	13.74
29	13.94	14.02
30	14.41	14.54
31	14.83	14.92
32	14.98	15.22
33	15.56	15.64
34	16.09	16.19
35	16.29	16.41
36	17.24	17.27
37	17.43	17.79
38	17.90	17.99
39	18.26	18.32
40	18.68	18.74
41	18.94	19.03
42	19.19	19.28

9. Wykryte przedziały słów z fragmentu "rano"

Nr słowa	Start (s)	Koniec (s)
1	0.45	0.50
2	0.54	0.90
3	0.93	0.95
4	1.11	1.21
5	1.57	1.67
6	1.82	1.90
7	2.06	2.09
8	2.13	2.52
9	2.58	2.64
10	3.33	3.46
11	3.61	3.67
12	3.99	4.16
13	4.59	4.71
14	5.08	5.15
15	6.18	6.38
16	6.66	6.73
17	6.92	6.96
18	7.18	7.42
19	7.60	7.73
20	8.12	8.25
21	8.51	8.55
22	8.79	9.08
23	9.27	9.36
24	9.93	10.05
25	11.01	11.17
26	11.62	11.77
27	12.27	12.35
28	12.85	12.98
29	13.41	13.56
30	13.72	13.78
31	14.04	14.13
32	14.29	14.42
33	14.76	14.84
34	14.97	15.11
35	15.33	15.43
36	15.70	15.77
37	16.67	16.91
38	17.01	17.10
39	17.31	17.47

40	17.61	17.84
41	18.03	18.11
42	18.32	18.39